

# 不平衡学习方法在信用卡欺诈检测任务中的比较研究

组员：葛奕、邱皓哲、徐鹤岩

## 1、问题定义

本项目主要研究信用卡欺诈检测中的不平衡二分类问题。具体问题是给定一系列信用卡交易的用 pca 降维过的特征向量，模型需要判断该交易是否为交易欺诈，class=0 表示正常交易，class=1 表示交易欺诈。然而由于欺诈交易占比较低，该任务拥有非常典型的类别不平衡的特征。

本项目的输入为交易样本的而数值特征，包括匿名化后的主成分特征 V1 到 V28，以及 Time 和 Amount 两个原始的数据特征。输出为二分类标签。正类为交易欺诈，负类为交易正常。

在评价指标方面，本实验不利用 Accuracy 作为唯一甚至是主要指标。由于对于不平衡任务，Accuracy 更容易被多数类主导，无法充分反映模型对于少数欺诈样本的识别效果。因此，本实验采取多指标评价，包括 AUPRC、Average Precision 两个指标可以评价模型对欺诈样本的排序能力；Macro-F1,Fraud-F1,Precision、Recall、Balanced Accuracy 和混淆矩阵用于评价在固定阈值下的分类表现。同时考虑到真是情况，本实验设计了自定义业务评分： $\text{Custom Score} = \text{TP} \times 10 - \text{FN} \times 20 - \text{FP}$ ，这个评分在之后的应用中也可以根据自己的业务需要进行修改。

## 2、数据

本文使用 Credit Card Fraud Detection 数据集。数据集中共有样本 85443 条，正常交易 85295 条，占总样本的 99.8%，欺诈交易 148 条，占总样本的 0.2%。

数据获取脚本：

```
import kagglehub
```

```
path = kagglehub.dataset_download("mlg-ulb/creditcardfraud")
```

数据由于已经经过了 pca 降维，因此并没有进行过多的预处理，主要是采用采用 stratified split 将数据划分为训练集、验证集和测试集，比例约为 train/val/test = 56%/14%/30%，并保证三个集合中的类别比例基本一致。

为避免数据泄漏，本实验严格遵循先划分数据、再进行标准化和重采样的流程。对于 Time 和 Amount 两个数值尺度差异较大的特征，使用 StandardScaler 进行标准化。scaler 只在训练集上 fit，然后分别 transform 训练集、验证集和测试

集。SMOTE 和 SMOTEENN 等重采样方法只作用于训练集，不作用于验证集和测试集，确保评估阶段仍保持真实类别分布。

### 3、方法

本实验首先比较三类基线模型 Logistic Regression（正则化强度为 1.0, max\_iter=1000）、Random Forest(Forestn\_estimators=25, max\_depth=10, min\_samples\_leaf=2)和 MLP（单隐藏层，16 个神经元，max\_iter=15, batch\_size=2048）。

本实验最主要应用与研究的方法是不平衡处理方法，主要比较 none、classweight、SMOTE 和 SMOTEENN。none 表示不做任何不平衡处理，用作原始对照。Class weight 通过提高少数样本在损失函数中的权重，使模型在训练时更关注欺诈样本。SMOTE 通过少数类近邻插值生成合成样本，从数据层面增加少数类样本数量。SMOTENN 在 SMOTE 之后进一步利用 ENN 清理边界和噪声样本。

此外，本次实验还研究了 threshold moving，降低被判定为欺诈的阈值，分析误报与漏报之间的权衡。

### 4、实验设置

所有实验使用相同的 train/val/test 划分，相同的标准化方法以及相同的评价指标。所有参数选择均基于验证集，测试集只用于最终评估，不参与参数选择或模型选择。

实验 1 为 baseline 模型比较。该实验不使用任何不平衡处理方法，阈值固定为 0.5，比较 LR、RF 和 MLP 在原始不平衡分布下的基础表现。

实验 2 为训练期不平衡方法比较。在固定 threshold=0.5 的条件下，对三类模型分别使用 none、class weight、SMOTE 和 SMOTEENN，观察不同不平衡处理方法对 Precision、Recall、FP、FN 和综合指标的影响。具体参数设置为 class\_weight="balanced"

实验 3 为 SMOTE 参数消融。本文设置 sampling\_strategy 为 0.1、0.3、0.5、1.0，k\_neighbors 为 3、5、7，分析过采样强度和近邻数对模型表现的影响。

实验 4 为 class weight 参数消融。本文设置正类权重为 1、2、5、10、20 和 balanced，在不使用 SMOTE 的情况下分析权重增强对 Recall、Precision、FP、FN 和 Custom Score 的影响。

实验 5 为阈值移动消融。该实验在不使用训练期不平衡处理的条件下，对每个模型扫描多个固定 threshold，包括 0.01、0.03、0.05、0.10、0.15、0.20、

0.25、0.30、0.35、0.40、0.45、0.50、0.60、0.70、0.80 和 0.90。该实验只用于分析阈值变化对分类结果的影响，不用于最终选择最优模型。

实验 6 为代表性训练方法与阈值移动组合实验。本文先根据验证集指标从 SMOTE 消融和 class weight 消融中选出每个模型的 best\_SMOTE 和 best\_class\_weight，然后对 none、best\_SMOTE、best\_class\_weight 和 SMOTEENN\_default 进行关键阈值扫描，观察训练期不平衡处理与阈值移动是否存在叠加收益。

5、实验结果


| model | AUPRC  | Average_Precision | Fraud_F1 | Precision | Recall | FP | FN | TP  | Custom_Score |
|-------|--------|-------------------|----------|-----------|--------|----|----|-----|--------------|
| LR    | 0.7078 | 0.7086            | 0.7315   | 0.8624    | 0.6351 | 15 | 54 | 94  | -155         |
| RF    | 0.8051 | 0.8028            | 0.8203   | 0.9722    | 0.7095 | 3  | 43 | 105 | 187          |
| MLP   | 0.5999 | 0.6014            | 0.7037   | 0.7787    | 0.6419 | 27 | 53 | 95  | -137         |

实验 1: Baseline 模型比较


| model | training_method | AUPRC  | Average_Precision | Fraud_F1 | Precision | Recall | FP   | FN | TP  | Custom_Score |
|-------|-----------------|--------|-------------------|----------|-----------|--------|------|----|-----|--------------|
| LR    | none            | 0.7078 | 0.7086            | 0.7315   | 0.8624    | 0.6351 | 15   | 54 | 94  | -155         |
| LR    | class_weight    | 0.7486 | 0.7115            | 0.1221   | 0.0656    | 0.8784 | 1851 | 18 | 130 | -911         |
| LR    | SMOTE           | 0.7507 | 0.7134            | 0.1135   | 0.0607    | 0.8649 | 1980 | 20 | 128 | -1100        |
| LR    | SMOTEENN        | 0.7653 | 0.7105            | 0.1076   | 0.0574    | 0.8649 | 2103 | 20 | 128 | -1223        |
| RF    | none            | 0.8051 | 0.8028            | 0.8203   | 0.9722    | 0.7095 | 3    | 43 | 105 | 187          |
| RF    | class_weight    | 0.7841 | 0.7833            | 0.7986   | 0.837     | 0.7635 | 22   | 35 | 113 | 408          |
| RF    | SMOTE           | 0.766  | 0.7657            | 0.5324   | 0.398     | 0.8041 | 180  | 29 | 119 | 430          |
| RF    | SMOTEENN        | 0.7141 | 0.7007            | 0.5369   | 0.4013    | 0.8108 | 179  | 28 | 120 | 461          |
| MLP   | none            | 0.5999 | 0.6014            | 0.7037   | 0.7787    | 0.6419 | 27   | 53 | 95  | -137         |

|     |              |        |        |        |        |        |      |    |     |      |
|-----|--------------|--------|--------|--------|--------|--------|------|----|-----|------|
| MLP | class_weight | 0.7026 | 0.7036 | 0.1568 | 0.0862 | 0.8649 | 1357 | 20 | 128 | -477 |
| MLP | SMOTE        | 0.7277 | 0.7283 | 0.1691 | 0.094  | 0.8446 | 1205 | 23 | 125 | -415 |
| MLP | SMOTEE NN    | 0.7225 | 0.7233 | 0.1639 | 0.0908 | 0.8446 | 1252 | 23 | 125 | -462 |

实验 2：不平衡处理方法比较



实验 3：SMOTE 参数消融（此处只放了 AUPRC）



实验 4: Class weight 参数消融

| model | threshold | AUPRC  | Average_Precision | Fraud_F1 | Precision | Recall | FP | FN | TP  | Custom_Score |
|-------|-----------|--------|-------------------|----------|-----------|--------|----|----|-----|--------------|
| RF    | 0.05      | 0.8051 | 0.8028            | 0.6873   | 0.5894    | 0.8243 | 85 | 26 | 122 | 615          |
| RF    | 0.1       | 0.8051 | 0.8028            | 0.7722   | 0.7262    | 0.8243 | 46 | 26 | 122 | 654          |
| RF    | 0.2       | 0.8051 | 0.8028            | 0.8188   | 0.8133    | 0.8243 | 28 | 26 | 122 | 672          |
| RF    | 0.3       | 0.8051 | 0.8028            | 0.8276   | 0.8451    | 0.8108 | 22 | 28 | 120 | 618          |
| RF    | 0.5       | 0.8051 | 0.8028            | 0.8203   | 0.9722    | 0.7095 | 3  | 43 | 105 | 187          |
| RF    | 0.7       | 0.8051 | 0.8028            | 0.7903   | 0.98      | 0.6622 | 2  | 50 | 98  | -22          |

实验五: Threshold 移动 (以 RF 为例分析)

| 方法                | 最优 threshold | AUPRC  | Fraud_F1 | Precision | Recall | FP  | FN | Custom_Score |
|-------------------|--------------|--------|----------|-----------|--------|-----|----|--------------|
| none              | 0.2          | 0.8051 | 0.8188   | 0.8133    | 0.8243 | 28  | 26 | 672          |
| best_SMOTE        | 0.3          | 0.8341 | 0.7251   | 0.6392    | 0.8378 | 70  | 24 | 690          |
| best_class_weight | 0.2          | 0.8051 | 0.8188   | 0.8133    | 0.8243 | 28  | 26 | 672          |
| SMOTEENN_default  | 0.5          | 0.7141 | 0.5369   | 0.4013    | 0.8108 | 179 | 28 | 461          |

实验 6: 组合实验 (选取最优的 threshold)

## 6、结果分析

实验一发现 baseline 中 RF 的效果整体优于 LR 和 MLP, 说明该数据集里存在明显的非线性关系以及特征之间的交互, 树模型更容易学到有效的边界。而 MLP 推测可能因为训练轮数不够或者参数数量不够。

实验二中发现, 单从 AUPRC 这个指标来看, RF 不加不平衡方法是最高的。但是如果看 custom\_score 来看, RF 加上不平衡方法之后有明显上升, 具体分析是由

于加上不平衡方法之后 TP 明显上升，但是随之 FP 也在上升，然而对于信用卡欺诈这个场景来说，很明显 TP 的上升更为关键。同时发现 SMOTE 比 classweight 的 FP 值高的多，因此基本可以确定问题可能出在欺诈与正常数据的边界上，由于加上了不平衡方法，一些原本靠近欺诈边界的正常类交易，更容易被判定为欺诈。

SMOTE 消融实验显示，不同模型对采样比例的敏感性不同。RF 的最优 AUPRC 出现在较小的 sampling\_strategy 下，而 LR 和 MLP 的 AUPRC 更倾向于在较大采样比例下提升。这可能是因为 RF 本身具有较强的非线性建模能力，少量合成样本已经足够增强少数类信息，过度采样反而会扭曲局部样本分布并增加误报。相比之下，LR 和 MLP 更容易受到多数类样本主导，需要更高比例的少数类样本来改变模型学习方向。但从 Custom Score 看，过大的采样比例会明显增加 FP，因此综合表现不一定最好。

实验五发现，threshold 不改变 AUPRC，这是因为改变阈值不会改变概率排序，但会显著改变 Precision、Recall、FP 和 FN。降低 threshold 可以减少漏报、提高 Recall，但会增加误报；提高 threshold 则相反。从 RF 结果来看，custom\_score 随着阈值的提高呈现一个先上升后下降的趋势，因此对于不平衡处理，阈值选择是一个比较关键的优化步骤，可以考虑贝叶斯优化等超参数优化方法进行选择最优阈值。

最终是对于性能测试来说最让人兴奋的组合实验结果。这里发现基本所有模型训练期处理和 threshold 移动加起来都会有更好的性能。同时在这里也出现了本次实验最高的 AUPRC 值也就是 RF+SMOTE 配合上 threshold，基本上可以得出多方法组合是可以提升模型处理不平衡方法能力的结论。

## 7、失败案例分析

失败案例 1：UCI Breast Cancer Wisconsin 数据集样本量过小

实验初期，我们首先尝试使用 UCI Breast Cancer Wisconsin 数据集进行不平衡分类实验。该数据集虽然适合二分类任务，但整体样本量较小，类别不平衡程度也不足以形成稳定、明显的实验差异。在这种情况下，训练集中的少数类样本数量有限，SMOTE 等过采样方法难以生成具有足够代表性的合成样本；class weight 虽然提高了少数类样本在损失函数中的权重，但由于原始数据规模较小，模型本身已经能够较容易地区分两类样本，因此加权后指标变化并不明显。

失败案例 2：最初只使用 Logistic Regression，忽略了模型选择的重要性

开始，我们计划只使用 Logistic Regression 作为模型，比较平衡方法的提升性能影响，但是发现调整参数后的性能提升并不理想。进一步分析发现，可能问题不只是不平衡方法本身，而是 LR 的模型表示能力有限，因此尝试使用处理非线性关系能力更好的模型，确实发现了实验效果的明显提升。

失败案例 3：只比较不同不平衡方法，忽略了方法内部参数的影响

我们原本只打算比较不平衡方法本身，当时实验设计的重点是使用哪一种不平衡方法更好。因此都使用固定参数比较。但是后续实验发现，同一种不平衡方法在不同参数下可能产生明显不同的结果。以 SMOTE 为例，`sampling_strategy` 控制少数类被过采样到什么程度。如果设置为 1.0，训练集会接近正负类 1:1 平衡，模型通常会更积极地预测欺诈类，Recall 可能提高，但 FP 也可能明显增加，Precision 下降。如果使用较小的 `sampling_strategy`，模型对少数类的敏感程度会下降，误报可能减少，但漏报可能增加。`k_neighbors` 也会影响合成样本的分布，近邻数不同会改变生成样本的局部特征，从而影响模型边界。因此，我们后续不再只做方法级比较，而是增加 SMOTE 参数消融和 `class weight` 参数消融。这样不仅能比较不同方法的最终效果，还能分析参数变化如何影响模型的误报、漏报和综合指标，从而更深入地理解不平衡处理方法背后的规律。

## 8、实验结论

- 1、本实验验证了信用卡欺诈检测中类别不平衡问题对模型评价的显著影响，由于 Accuracy 容易被多数类主导，不能作为主要指标。因此试验结合 AUPRC、Fraud-F1、Custom Score 和混淆矩阵综合判断。
- 2、Baseline 中 RF 整体由于 LR 和 MLP。
- 3、不平衡的处理方法能够提高模型对于欺诈类样本的识别精度，但同时也会带来更多的误报。
- 4、MOTE 和 `class weight` 的效果依赖参数设置，过强的处理并不一定更好。阈值移动虽然不改变 AUPRC，但能明显调节 Precision、Recall、FP 和 FN。
- 5、不平衡方法有时在自己的打分机制上的优化效果会高于 AUPRC 等评价指标，有一定的现实意义。

## 9、诚信说明

本项目使用大模型辅助进行了代码格式润色、局部 bug 排查、报告表格格式优化，以及少量语法和逻辑表达修改。实验设计、代码主体、模型运行、结果生成和结果分析均由小组成员完成。未使用大模型自动生成整段代码或完整报告正文，也未使用大模型伪造或替代实验结果。

Github 链接：[https://github.com/loopydad/Imbalanced\\_machinelearning\\_ml3](https://github.com/loopydad/Imbalanced_machinelearning_ml3)